

Relatório Técnico:

Análise_de_Classificação_com_Redes_Convolucionais_e_o_dataset_CUFS

Grupo 99:

Gabriel Marçal de Oliveira

Leon Santana Barbosa

Data de entrega: 03/12/24

Resumo

O objetivo deste trabalho foi aplicar uma Rede Neural Convolucional (CNN) para a classificação de imagens de rostos quanto ao sexo biológico (Masculino ou Feminino). A tarefa foi realizada utilizando um modelo arquitetado com camadas convolucionais e de pooling, seguidas por camadas densas para a classificação final. Durante o treinamento, o modelo foi ajustado para reconhecer as características faciais que indicam o sexo biológico das imagens. O conjunto de dados foi dividido em três partes: treinamento, validação e teste, sendo que o modelo passou por 15 épocas de treinamento.

O desempenho do modelo foi avaliado com base em métricas de acurácia, precisão, recall, F1-score e perda (loss). Os resultados indicaram uma acurácia de 92,1% no conjunto de teste, refletindo um bom desempenho geral. No entanto, observou-se que a precisão e o recall para a classe Masculino foram mais elevados, alcançando 0,93 e 0,96, respectivamente, enquanto para a classe Feminino, os valores foram ligeiramente mais baixos (0,89 e 0,80, respectivamente). O F1-score ponderado foi de 0,92, destacando a boa performance do modelo na classificação das duas classes, embora haja um ligeiro desvio a favor da classe Masculino.

Esses resultados sugerem que o modelo tem uma boa capacidade de generalização, mas que o desbalanceamento entre as classes pode ter influenciado a performance de maneira desigual. A limitação de imagens da classe Feminino pode ter afetado o desempenho, indicando a necessidade de ajustes no dataset e melhorias no treinamento. Como melhorias, pode-se considerar o uso de técnicas de aumento de dados e ajustes na arquitetura da rede para melhorar a acurácia da classe Feminino e reduzir o desbalanceamento.

Introdução

O problema de classificação de imagens, especificamente a identificação de características faciais e a categorização de indivíduos em grupos específicos, tem sido um tema de grande interesse e avanço na área de aprendizado de máquina, especialmente nas redes neurais convolucionais (CNNs). Essas redes têm se mostrado altamente eficazes na extração de características complexas de imagens, permitindo que modelos automatizados realizem tarefas de classificação com alta precisão. A capacidade das CNNs de identificar padrões espaciais em imagens torna-as ideais para problemas relacionados à visão computacional, como reconhecimento facial, análise de expressões e até mesmo diagnóstico médico por imagem.

Neste contexto, a classificação de rostos humanos de acordo com o sexo biológico é um desafio clássico, amplamente explorado tanto na academia quanto na indústria. A tarefa envolve a detecção e análise de características faciais que são, muitas vezes, sutis, mas ainda assim podem ser discriminadas de maneira eficaz com o uso de redes convolucionais. A habilidade das CNNs em detectar e aprender automaticamente essas características a partir de grandes volumes de dados tem sido um dos principais fatores que impulsionaram sua adoção em diversos domínios da inteligência artificial.

A aplicação de CNNs para classificar imagens de rostos quanto ao sexo biológico é particularmente relevante em diversas áreas, incluindo segurança, marketing, e até em estudos biométricos. No entanto, esses modelos enfrentam desafios, como o desbalanceamento entre as classes (homens e mulheres), variações de iluminação, ângulos das imagens e ruídos. Este trabalho tem como objetivo investigar a utilização de uma CNN para classificar imagens de rostos quanto ao sexo, avaliando seu desempenho e identificando as limitações do modelo para esse tipo de tarefa.

O sucesso desse tipo de modelo pode fornecer insights importantes para o desenvolvimento de sistemas mais robustos de reconhecimento facial e outras aplicações de visão computacional que dependem da precisão na classificação de imagens.

Metodologia

O processo de desenvolvimento do modelo de classificação de imagens foi conduzido em várias etapas fundamentais, começando pela preparação dos dados. O dataset utilizado consistia em imagens de rostos humanos, categorizadas em duas classes: masculino e feminino. Antes de alimentar essas imagens na rede neural, foi necessário realizar um pré-processamento adequado, que incluiu a normalização das imagens para uma faixa de valores entre 0 e 1 e o redimensionamento das imagens para um tamanho uniforme, o que é crucial para garantir que o modelo processasse as imagens de forma eficiente.

O modelo proposto foi construído utilizando a arquitetura padrão de uma rede neural convolucional (CNN), com três camadas convolucionais, seguidas de camadas de pooling para redução dimensional e uma camada densa final para a classificação. A rede convolucional inicial foi projetada com camadas de convolução com filtros de tamanhos variados (32, 64 e 128), para capturar características de baixo e alto nível nas imagens. As camadas de pooling (MaxPooling2D) foram aplicadas após cada camada convolucional para reduzir a dimensionalidade das representações das imagens, facilitando o treinamento e evitando o overfitting.

Além disso, foi implementada uma camada densa com 128 unidades após a última camada convolucional, conectada a uma camada de saída com duas unidades (uma para cada classe: masculino e feminino). A função de ativação utilizada foi a softmax, que é comumente empregada em problemas de classificação binária. Para evitar o overfitting, uma camada de dropout foi aplicada entre as camadas densas.

O treinamento do modelo foi realizado por 15 épocas, com um batch size de 32 e utilizando a função de perda de entropia cruzada (categorical crossentropy). A métrica de avaliação utilizada foi a acurácia, que foi calculada tanto nos dados de treinamento quanto nos dados de validação.

Após o treinamento, o modelo foi avaliado nos dados de teste, e diversas métricas de desempenho, como precisão, recall e F1-score, foram utilizadas para medir a eficácia do modelo. Esses resultados permitiram uma análise mais detalhada sobre o equilíbrio entre as classes e a eficácia do modelo em classificar imagens de maneira consistente

Discussão

A análise dos resultados obtidos durante o treinamento e avaliação do modelo revela alguns insights importantes sobre o desempenho da rede neural convolucional aplicada à classificação de rostos quanto ao sexo biológico. A F1-score do modelo foi alta (especialmente para a classe masculina), indicando que o modelo conseguiu alcançar um bom equilíbrio entre as métricas de precisão e recall, sugerindo que as classificações feitas não foram excessivamente enviesadas em favor de uma classe. No entanto, o desempenho da classe feminina foi um pouco mais baixo, com um recall de 0.80 e uma F1-score de 0.84, o que indica que o modelo teve um desempenho inferior ao classificar rostos femininos em comparação com rostos masculinos.

Uma possível explicação para essa discrepância pode estar relacionada a características intrínsecas ao dataset, como a distribuição desigual entre as classes. O número de imagens de rostos masculinos e femininos pode não ter sido equilibrado, o que pode ter influenciado a capacidade do modelo de aprender padrões representativos para a classe feminina. A qualidade das imagens também pode ter desempenhado um papel importante, especialmente em casos de imagens com baixa resolução, iluminação insuficiente ou ângulos desfavoráveis. Isso pode ter dificultado o processo de aprendizado do modelo, levando a um desempenho inferior na classificação de rostos femininos.

Além disso, ao analisar os erros de classificação, percebe-se que os erros mais frequentes ocorreram em imagens com iluminação inadequada ou com ângulos muito laterais, o que sugere que o modelo pode ter dificuldades em aprender características faciais em tais condições. A presença de ruído ou deformações nas imagens também pode ser uma das causas para os erros.

Em termos de possíveis melhorias, uma modificação no dataset, como a adição de mais imagens balanceadas para as classes e uma melhor qualidade de imagens, poderia ajudar o modelo a aprender de forma mais robusta. Além disso, aumentar a complexidade da arquitetura, como adicionar mais camadas convolucionais ou usar técnicas de data augmentation (aumento de dados), poderia ajudar a melhorar o desempenho do modelo, especialmente para a classe feminina.

Conclusão

Este trabalho demonstrou que redes neurais convolucionais são eficazes para a classificação de rostos humanos quanto ao sexo biológico, com bons resultados de precisão e F1-score, especialmente para a classe masculina. Contudo, o modelo apresentou dificuldades ao classificar imagens femininas, o que pode ser atribuído ao desbalanceamento entre as classes e a qualidade das imagens no dataset. Apesar disso, o modelo alcançou uma acurácia geral de aproximadamente 92% nos dados de teste, o que é um resultado promissor para um modelo inicial.

Os principais aprendizados desta atividade incluem a importância do pré-processamento e da escolha do modelo para garantir um bom desempenho em tarefas de classificação de imagens. A análise crítica também revelou que a qualidade e a diversidade do dataset são fatores cruciais para melhorar o desempenho de modelos de classificação facial. A implementação de técnicas como data augmentation e balanceamento das classes pode ser uma solução para mitigar os problemas encontrados.

Como sugestões para trabalhos futuros, seria interessante explorar a utilização de técnicas de transferência de aprendizado, usando modelos pré-treinados em grandes datasets de reconhecimento facial. Isso poderia reduzir o tempo de treinamento e melhorar a acurácia, especialmente para classes com menos dados. Além disso, novas arquiteturas de CNNs mais avançadas, como as redes residuais (ResNet) ou redes mais profundas, poderiam ser experimentadas para tentar capturar características faciais mais sutis e melhorar o desempenho geral do modelo.

Referências

https://neo4j.com/docs/graph-data-science/current/algorithms/knn/?utm_source=GSearch&utm_medium=PaidSearch&utm_campaign=Evergreen&utm_content=AMS-Search-SEMCE-D [SA-None-SEM-SEM-NonABM&utm_term=&utm_adgroup=DSA&gad_source=1&gclid=CjwKCAiAxea5BhBeEiwAh4t5K3Q3H3dWDYd_a-yWxJ-RDi9ISsiv3SNHPYBT5fqBGhcFMB4zIUt_0TxoC-NcQAvD_BwE](#)

<https://medium.com/brasil-ai/knn-k-nearest-neighbors-1-e140c82e9c4e>

<https://www.ibm.com/br-pt/topics/convolutional-neural-networks>

<https://medium.com/data-hackers/como-funcionam-as-redes-neurais-convolucionais-cnns-71978185c1>